BRIGHTLEARN - GRUPO 3

NOMES: NATHÁLIA VERRI
ARTHUR ENRIQUE ALVES DE MACEDO
VITORIA RODRIGUES BARBOSA
RAUL RODRIGUES FREITAS

2º ETAPA

Preparo e limpeza dos dados

Ao analisar a base da BrightLearn, encontramos problemas na escrita das **categorias**, **valores impossíveis** de percentual concluído, **notas em branco** e alguns tempos de primeiro acesso **muito acima do normal**. Nenhuma linha da base foi excluída.

Na coluna **Categoria_Curso**, a mesma categoria aparecia escrita de jeitos diferentes (maiúsculas, sem acento, com espaço sobrando), em 21 registros. **Padronizamos os nomes** para cada categoria ser contada uma vez só.

Na coluna **Pct_Concluido**, 8 registros tinham **140%**, o que é impossível. Nos 6 alunos **Concluídos**, trocamos por **100%**. Nos outros 2 (1 Em andamento e 1 Evadido) não dá para saber o valor certo, então **deixamos em branco** e eles ficam fora do cálculo do percentual. Para resumir, usamos a **mediana**, que ficou em **82,35%**, porque a média é muito puxada pelos grupos de 100% e de evadidos.

Na coluna **Nota_Final**, havia **454 células vazias**. Em 439 delas o aluno não concluiu o curso, então não tem nota e deixamos em branco. Os outros 15 eram concluídos sem nota, e também **deixamos em branco**, em vez de inventar um valor. Testamos preencher com a mediana (7,6) e a média dos concluídos quase não muda (**7,499 contra 7,503**), então a escolha não altera o resultado. Resumimos a nota pela **mediana**, 7,6.

Na coluna **Dias_Ate_Primeiro_Acesso**, **60 registros** passaram de 8,5 dias, chegando a 24. Não são erros, são alunos que demoraram para começar, e isso tem tudo a ver com a nossa pergunta, então **mantivemos**. Resumimos pela **mediana**, que deu **2 dias** (a média é 3,02, puxada por esses casos).

Por fim, a **moda** mostrou que **Tecnologia** é a categoria mais frequente, com 215 registros, e que **"Falta de tempo"** é o motivo de evasão mais citado, com 88 registros. Os 42 evadidos com motivo "Não informado" foram mantidos como uma categoria própria.

Antes e depois do tratamento:

Indicador	Antes	Depois
Tecnologia (registros)	205	215
Marketing (registros)	158	166
Negócios (registros)	146	149
Design (registros)	149	149
Idiomas (registros)	141	141
Pct_Concluido: valor máximo	140%	100%
Pct_Concluido: média	66,85%	66,38%
Pct_Concluido: mediana	82,50%	82,35%
Pct_Concluido: registros usados	820	818
Nota_Final: média dos concluídos	7,499	7,499 (366 notas)